

SÃO PAULO TECH SCHOOL
Sistema da Informação

Jonathan Alborghetti Almeida - RA: 03231027
Guilherme Gonçalves Silva Santos – RA: 03231037
Giovanna Freitas Bezerra – RA: 03231050
Natália Campioli Russo - RA: 03231010
Paola Ribeiro Gomes – RA: 03231051

Projeto de TCC: BusFlow
Automação Inteligente de Despacho de Frota de Ônibus via
Machine Learning e Dados Climáticos

São Paulo
2026

SUMÁRIO

1	RESUMO	7
2	INTRODUÇÃO E CONTEXTO	8
3	JUSTIFICATIVA E PROBLEMATIZAÇÃO.....	9
3.1	Análise do Processo Atual (<i>As-Is</i>)	9
3.2	Proposta do Processo Futuro (<i>To-Be</i>).....	10
4	OBJETIVOS E ESCOPO DA SOLUÇÃO	12
4.1	Objetivo Geral	12
4.2	Objetivos Específicos (Modelagem Preditiva)	12
4.3	Escopo Proposto	12
4.4	Personas Envolvidas.....	13
5	ARQUITETURA DA SOLUÇÃO E FLUXO DE DADO	14
5.1	Desenho da Arquitetura em Nuvem	14
5.2	Componentes da Arquitetura AWS	14
5.2.1	Fontes de Dados:.....	14
5.2.2	Ingestão — Camada Raw/Bronze:.....	15
5.2.3	Tratamento — Camada Trusted/Silver:.....	15
5.2.4	Inteligência Artificial:.....	15
5.2.5	Consumo e Mensageria:	15
6	DICIONÁRIO DE DADOS.....	16
6.1	Tabela A: API SPTrans Olho Vivo	16
6.2	Tabela B: API OpenWeather	16
6.3	Tabela C: SPTrans GTFS (Estático)	17
7	ANÁLISE DE CUSTOS E VIABILIDADE FINANCEIRA (FINOPS).....	18
7.1	Estimativa de Custos AWS	18
7.2	Análise de Viabilidade e Retorno Operacional	18
8	REFERÊNCIAS	19

1 RESUMO

O setor de mobilidade urbana nos grandes centros enfrenta ineficiências na alocação de frotas operacionais, operando predominantemente por meio de planejamentos estáticos e históricos fixos. Este trabalho apresenta o **BusFlow**, uma solução preditiva em nuvem voltada para o Centro de Controle Operacional (CCO) de empresas de transporte coletivo. Ao cruzar dados telemétricos em tempo real da SPTrans com dados meteorológicos via aprendizado de máquina (*Machine Learning*), o sistema antecipa picos de demanda decorrentes de intempéries climáticas e sugere ações de despacho em tempo real. A arquitetura foi desenvolvida sobre a plataforma AWS utilizando o padrão *Medallion* e o paradigma *Serverless*. Uma pesquisa qualitativa com profissionais do setor fundamentou a dor operacional *As-Is*, validando a necessidade do painel gerencial no cenário *To-Be*.

Palavras-chave: Mobilidade Urbana; Machine Learning; Serverless; AWS; Gestão de Frota.

2 INTRODUÇÃO E CONTEXTO

O transporte público rodoviário nas grandes metrópoles, em especial no município de São Paulo, sofre historicamente com a rigidez dos modelos tradicionais de operação. Atualmente, a gestão de oferta e frota baseia-se em tabelas horárias estáticas e dados históricos passivos.

Esse modelo desconsidera variáveis dinâmicas e externas, com destaque para os eventos meteorológicos. Dias com clima favorável geram veículos ociosos e custos desnecessários. Por outro lado, precipitações intensas provocam aumento repentino na procura pelo transporte coletivo, redução severa na velocidade das vias e o surgimento do "efeito comboio" (veículos à frente superlotados seguidos por veículos vazios atrasados).

Nesse cenário, insere-se o conceito de *Smart Cities* e práticas de *ESG/Green IT*, buscando uma tomada de decisão orientada a dados (*data-driven*). O projeto **BusFlow** surge como uma ferramenta para transformar o modelo operacional reativo em um processo preditivo e automatizado de despacho.

3 JUSTIFICATIVA E PROBLEMATIZAÇÃO

A perda de eficiência operacional do transporte por ônibus na cidade de São Paulo é evidenciada por dados do setor:


- Redução de Frota: Entre 2019 e 2024, a frota operacional encolheu aproximadamente 5,8% (de 14.103 para 13.281 veículos) (SPTRANS, 2024).
- Impacto no Atendimento: No mesmo período, o tempo médio de espera aumentou em cerca de 20%, e a velocidade média nos corredores exclusivos caiu perto de 9% (IPEA, 2024).
- Gargalo Climático: O impacto das chuvas agrava drasticamente este cenário, culminando em picos de congestionamento histórico (como o registro de 1.348 km de lentidão em 2026) (CET-SP, 2026).

3.1 Análise do Processo Atual (As-Is)

Para compreender a dinâmica real da operação, realizou-se uma entrevista qualitativa com profissionais operacionais do transporte coletivo. A análise do processo *As-Is* revelou os seguintes gargalos:

- Comunicação Descentralizada e Reativa: O contato entre motoristas e centrais diante de acidentes, alagamentos ou desvios ocorre precipuamente por rádio comunicador ou grupos informais no *WhatsApp*.
- Tomada de Decisão Empírica: A escolha de rotas alternativas é feita, na maioria dos casos, pela experiência individual do próprio motorista quando ele encontra o bloqueio.
- Visibilidade Tardia do CCO: A central operacional só identifica que uma linha estourou ou colapsou depois que o gargalo ocorreu.
- Frota Engessada: A redistribuição de carros extras ocorre apenas em eventos previamente programados (shows, jogos) ou greves, não havendo flexibilidade rápida para lidar com intempéries climáticas repentinas.

Figura 1 – Mapeamento de Processo Atual (As-Is)



Fonte: Elaborado pelos autores (2026).

3.2 Proposta do Processo Futuro (*To-Be*)

O modelo *To-Be* introduz a automação preditiva na tomada de decisão do CCO. Em vez de aguardar a notificação do motorista via rádio ou grupos de *WhatsApp*, o sistema atua de forma preventiva:

- **Monitoramento Automatizado de Clima e Tráfego:** A ingestão contínua cruza a telemetria dos ônibus com previsões de precipitação pluviométrica em tempo real.
- **Emissão de Alerta Preditivo:** O modelo de Machine Learning identifica o risco de superlotação e lentidão antes que o evento ocorra, emitindo um alerta visual na tela do operador do CCO.
- **Despacho Preventivo:** O CCO autoriza o envio de veículos extras/reserva da garagem ou a alteração programada da frota com antecedência, evitando o colapso da linha e o tempo excessivo de espera na chuva.

- Comunicação Integrada: As instruções de despacho preventivo geradas pelo sistema são centralizadas no Dashboard do CCO, permitindo que o operador formalize o envio de veículos adicionais diretamente aos canais operacionais da garagem ou aos chefes de pátio.

Figura 2 – Mapeamento do Processo Futuro Proposto (*To-Be*)

Fonte: Elaborado pelos autores (2026).

4 OBJETIVOS E ESCOPO DA SOLUÇÃO

4.1 Objetivo Geral

Desenvolver e validar um ecossistema preditivo em nuvem fundamentado em aprendizado de máquina (*Machine Learning*) para correlacionar dados de transporte e variáveis meteorológicas em tempo real, apoiando os operadores dos Centros de Controle Operacional (CCO) no despacho preventivo e dinâmico da frota de ônibus.

4.2 Objetivos Específicos (Modelagem Preditiva)

Para viabilizar a tomada de decisão orientada a dados no CCO, a solução apoia-se nos seguintes objetivos técnicos específicos:

- Injeção de Dados Multifonte: Estruturar um pipeline de ingestão para dados telemétricos em tempo real (API SPTrans), dados climáticos históricos e operacionais em tempo real (API OpenWeather) e malha geoespacial estática (GTFS).
- Engenharia de Recursos (*Feature Engineering*): Extrair variáveis preditivas relevantes, como índice de precipitação pluviométrica acumulada (rain.1h), horário de pico, velocidade média do trecho e desvio de pontualidade, preparando o *dataset* no padrão *Medallion* (Silver).
- Treinamento e Modelagem Preditiva: Treinar e avaliar algoritmos de regressão e classificação de séries temporais (como XGBoost via *Amazon SageMaker*) para prever a probabilidade de gargalos de demanda, atrasos críticos e o tempo estimado de chegada (ETA) sob condições climáticas adversas.
- Geração de Alertas em Tempo Real: Estabelecer limiares de inferência no modelo para disparar alertas preventivos automatizados direcionados à torre de controle.

4.3 Escopo Proposto

Incluso no Escopo:

- Pipeline de ingestão, tratamento e anonimização de dados (atendendo à LGPD) em nuvem AWS.
- Modelo preditivo de *Machine Learning* treinado e hospedado em endpoint gerenciado (*Amazon SageMaker*).

- Dashboard de BI (CCO): Interface gerencial voltada ao CCO para visualização em tempo real da malha operacional, destacando o indicador preditivo do modelo de IA (ex: *"Linha X: Risco elevado de superlotação em 40 minutos devido a volume de chuva de 15mm/h; Sugestão: Despachar 2 veículos reservas da garagem Y"*).
- Camada de banco de dados e mensageria (*Amazon RDS + Amazon SNS*) para auditoria dos alertas emitidos.

Fora do Escopo:

- Desenvolvimento de aplicativos móveis nativos para fiscais ou motoristas em pátio. As orientações da central continuam sendo transmitidas pelos canais operacionais padrão da concessionária (sistemas internos/rádio).
- Integração física com o validador/catraca do ônibus ou sistemas proprietários de telemetria das concessionárias que não disponibilizem API aberta.


4.4 Personas Envolvidas

O usuário primário da solução é o Operador / Controlador de Tráfego do CCO das concessionárias privadas de transporte. Este profissional atua imerso em múltiplos monitores regulando a operação da cidade. O BusFlow atua diretamente como um sistema de suporte à decisão para este operador, substituindo a intuição por predição baseada em inteligência artificial.

5 ARQUITETURA DA SOLUÇÃO E FLUXO DE DADO

5.1 Desenho da Arquitetura em Nuvem

Figura 3 – Diagrama da Arquitetura AWS e Pipeline de Dados (BusFlow)



Fonte: Elaborado pelos autores (2026).

5.2 Componentes da Arquitetura AWS

5.2.1 Fontes de Dados:

- API SPTans (Olho Vivo): Dados telemétricos via repositório de dados abertos e endpoints JSON (localização GPS, prefixo, sentido, linha).
- API OpenWeather: Variáveis atmosféricas em tempo real (volume pluviométrico, temperatura, condição geral).
- SPTans GTFS: Arquivos estáticos estruturados (shapes.txt, trips.txt, stop_times.txt) para mapeamento geoespacial da malha urbana.

5.2.2 Ingestão — Camada Raw/Bronze:

- O Amazon EventBridge dispara a função AWS Lambda em intervalos regulares, extraindo o estado das APIs e persistindo arquivos brutos no bucket s3-raw-busflow.

5.2.3 Tratamento — Camada Trusted/Silver:

- Gatilhos de armazenamento acionam funções de limpeza, mascaramento/anonimização para atendimento à LGPD, junção relacional das fontes e conversão para formatos tabulares otimizados no bucket s3-trusted-busflow.

5.2.4 Inteligência Artificial:

- Utilização do algoritmo XGBoost (via SageMaker Autopilot / Treinamento Gerenciado) para cruzamento de séries temporais climáticas com histórico de deslocamento, estimando o tempo de chegada (ETA) e prevendo anomalias de demanda.

5.2.5 Consumo e Mensageria:

- Predições e telemetria são gravadas em um banco relacional Amazon RDS (PostgreSQL). O Metabase realiza a renderização gráfica no CCO, enquanto o Amazon SNS encaminha notificações de eventos críticos.

6 DICIONÁRIO DE DADOS

6.1 Tabela A: API SPTrans Olho Vivo

Chave (JSON)	Tipo	Descrição do Dado Bruto	Importância para o BusFlow
hr	String	Horário de referência da extração	Define o momento da captura da frota.
cl	Inteiro	Código identificador da linha	Chave primária para cruzamento GTFS.
sl	Inteiro	Sentido da operação (1 ou 2)	Identifica sentido ida/volta.
p	String	Prefixo (ID) do veículo	Rastreamento individual do veículo.
py / px	Float	Latitude e Longitude atual	Cálculo de velocidade e deslocamento.
ta	String	Horário de envio do sinal GPS	Identificação de latência de rede vs. trânsito.

6.2 Tabela B: API OpenWeather

Chave (JSON)	Tipo	Descrição do Dado Bruto	Importância para o BusFlow
dt	Inteiro	Timestamp da medição (Unix)	Sincronização temporal com a SPTrans.
weather[0].main	String	Categoria climática (ex: Rain, Clear)	Categoria primária para o modelo ML.
main.temp	Float	Temperatura atual (°C)	Variável secundária de demanda.

Chave (JSON)	Tipo	Descrição do Dado Bruto	Importância para o BusFlow
rain.1h	Float	Volume de chuva (mm na última hora)	Variável crítica de severidade climática.

6.3 Tabela C: SPTrans GTFS (Estático)

Arquivo (.txt)	Colunas Essenciais	Descrição do Dado Bruto	Importância para o BusFlow
shapes.txt	shape_id, shape_pt_lat, shape_pt_lon, shape_pt_sequence	Trajeto geoespacial exato da linha	Mapeia a rota do veículo e identifica se houve desvio por alagamento.
trips.txt	route_id, trip_id, shape_id	Mapeamento de rotas e viagens	Faz a ponte entre a linha comercial e o código da viagem no sistema.
stop_times.txt	trip_id, arrival_time, stop_id	Quadro de horários teóricos previstos	Base teórica de pontualidade para o cálculo de atrasos e tempo de chegada (ETA).

7 ANÁLISE DE CUSTOS E VIABILIDADE FINANCEIRA (FINOPS)

A análise econômico-financeira do projeto avaliou os custos de infraestrutura no ecossistema AWS com orquestração via *Terraform*, visando manter um custo reduzido para o desenvolvimento do MVP/POC.

7.1 Estimativa de Custos AWS

Componente AWS	Recurso Especificado	Custo Estimado Mensal (USD)
AWS Lambda	Processamento Serverless ETL	US\$ 0,50 ~ US\$ 2,00
Amazon S3	Data Lake (Bronze/Silver)	US\$ 1,00
Amazon SageMaker	Treinamento e Inferência ML	US\$ 8,00 ~ US\$ 15,00
Amazon RDS	PostgreSQL DB Instance	US\$ 12,00 ~ US\$ 18,00
Amazon EC2	Web Application / Dashboard	US\$ 8,00 ~ US\$ 18,00
Endpoints & outros	VPC Endpoints / SNS	US\$ 5,00 ~ US\$ 15,00
TOTAL ESTIMADO	Ambiente POC/MVP	US\$ 35,00 ~ US\$ 63,00

7.2 Análise de Viabilidade e Retorno Operacional

Viabilidade Econômica: Custo de execução baixo devido à ausência de servidores ociosos (*Serverless*), uso do ecossistema *Open Source* (*Metabase*, *Python*, *PostgreSQL*) e gratuidade das APIs abertas.

Retorno Esperado (ROI Operacional): Estimativa de 20% a 35% de redução no tempo de resposta operacional do CCO, além de otimização no consumo de combustível e diminuição da quilometragem ociosa rodada desnecessariamente.

8 REFERÊNCIAS

- AMAZON WEB SERVICES. **AWS Serverless Multi-Tier Architectures**. Disponível em: <https://aws.amazon.com/whitepapers/>. Acesso em: 2026.
- SÃO PAULO (Estado). **SPTrans - API Olho Vivo e GTFS**. São Paulo: SPTrans, 2026. Disponível em: <https://www.sptrans.com.br/desenvolvedores/>. Acesso em: 2026.
- OPENWEATHERMAP. **Current Weather Data API Reference**. Disponível em: <https://openweathermap.org/api>. Acesso em: 2026.