

Análise de Opções de IA para o Projeto BusFlow

Objetivo: identificar as alternativas mais viáveis de Inteligência Artificial/Machine Learning para prever impactos operacionais no transporte público a partir de dados climáticos e dados da frota, gerando alertas e insights para apoio à tomada de decisão do CCO.

1. Opções mais viáveis

Random Forest (Scikit-Learn): Modelo supervisionado de fácil implementação. Possui boa precisão para dados tabulares, é explicável e amplamente utilizado em projetos acadêmicos.

XGBoost: Algoritmo muito utilizado em previsão de demanda e problemas operacionais. Geralmente apresenta melhor desempenho que modelos tradicionais, porém exige mais ajustes.

Gradient Boosting (Scikit-Learn): Alternativa intermediária entre simplicidade e desempenho. Integra facilmente com Python e possui boa documentação.

Amazon SageMaker: Plataforma AWS para treinamento e gerenciamento de modelos. Pode ser utilizada caso a conta educacional permita acesso aos recursos necessários.

2. Comparativo resumido

Random Forest

Facilidade de uso: Alta

Facilidade de configuração: Alta

Custo: Gratuito

Recomendação: Excelente para POC e TCC.

XGBoost

Facilidade de uso: Média

Facilidade de configuração: Média

Custo: Gratuito

Recomendação: Melhor desempenho, porém exige mais experimentação.

Gradient Boosting

Facilidade de uso: Média/Alta

Facilidade de configuração: Média

Custo: Gratuito

Recomendação: Boa alternativa para comparação de resultados.

SageMaker

Facilidade de uso: Média

Facilidade de configuração: Média/Alta

Custo: Dependente da conta AWS

Recomendação: Utilizar apenas se os recursos educacionais estiverem disponíveis.

3. Processo de validação dos modelos (passo a passo)

Passo 1 – Coletar dados históricos de clima (chuva, temperatura) e operação (GPS, velocidade média, ocupação ou demanda).

Passo 2 – Limpar e padronizar os dados, removendo inconsistências e valores ausentes.

Passo 3 – Definir a variável alvo (ex.: necessidade de reforço de frota, demanda prevista ou risco operacional).

Passo 4 – Separar os dados em treinamento (80%) e teste (20%).

Passo 5 – Treinar o primeiro modelo (Random Forest).

Passo 6 – Avaliar os resultados utilizando métricas adequadas (R^2 , RMSE, MAE ou Accuracy, dependendo do problema).

Passo 7 – Treinar modelos alternativos (XGBoost e Gradient Boosting).

Passo 8 – Comparar os resultados e selecionar o modelo com melhor desempenho e facilidade de manutenção.

Passo 9 – Salvar o modelo treinado e integrá-lo ao pipeline da solução.

Passo 10 – Validar os insights gerados junto aos especialistas ou usuários do processo.

4. Como a IA ajudará o BusFlow

A IA analisará simultaneamente dados climáticos e dados operacionais da frota para identificar padrões e prever situações críticas. Exemplos:

- Identificar aumento de demanda associado a chuvas intensas.
- Detectar risco de superlotação em determinadas linhas e horários.
- Sugerir reforço de frota em regiões com maior probabilidade de atraso.
- Indicar redução de veículos em períodos de baixa demanda.
- Apoiar o operador do CCO com alertas e recomendações baseadas em dados.

5. Recomendação Final

Para o contexto acadêmico do projeto BusFlow, a alternativa mais recomendada é utilizar Python + Scikit-Learn com Random Forest como modelo inicial. A solução possui baixo custo, facilidade de implementação, ampla documentação e não depende de recursos avançados da AWS. O SageMaker pode ser utilizado como alternativa complementar caso os recursos educacionais estejam disponíveis.